南京师范大学

毕业设计（论文）开题报告

姓　　名：杨智　　学　　号：19220119

学　　院：计算机与电子信息/人工智能学院

专　　业：计算机科学与技术

题　　目：融合多源视频数据的异常行为检测方法研究与实现

指导教师：胡勇

2026 年 1 月 12 日

开题报告填写要求

1．开题报告作为毕业设计（论文）答辩委员会对学生答辩资格审查的依据材料之一。此报告应在指导教师指导下，由学生在毕业设计（论文）工作前期内完成，经指导教师签署意见及院、系审查后生效；

2．开题报告内容必须用黑墨水笔工整书写或按教务处统一设计的电子文档标准格式（可从教务处网址上下载）打印，禁止打印在其它纸上后剪贴，完成后应及时交给指导教师签署意见；

3．有关年月日等日期的填写，应当按照国标 GB/T 7408—94《数据元和交换格式、信息交换、日期和时间表示法》规定的要求，一律用阿拉伯数字书写。如“2024 年 1 月 10 日”或“2024-01-10”。

毕 业 设 计（论 文）开 题 报 告

1. 本课题的目的及研究意义

研究目的：

随着智慧城市建设的深入推进和公共安全需求的日益增长，视频监控系统已成为城市安全管理的重要基础设施。然而，传统的单视角视频监控系统在异常行为检测方面存在诸多局限性。单一摄像头的视角受限、容易产生遮挡、难以全面捕捉复杂场景中的异常行为，这些问题严重制约了智能监控系统的有效性。特别是在人流密集的公共场所，如地铁站、机场、广场等区域，异常行为的及时发现和准确识别对公共安全至关重要。

多源视频数据融合技术为解决上述问题提供了新的思路。通过整合来自不同视角、不同位置摄像头的视频信息，可以构建更加全面、立体的监控视野，有效减少监控盲区，提高异常行为检测的准确性和鲁棒性。然而，多源视频数据的融合面临着视角差异、时空同步、特征表达等多方面的技术挑战。

本研究的主要目的是探索并开发融合多源视频数据的异常行为检测方法，突破单视角监控的局限性，为智能监控系统提供更加可靠和高效的技术支撑。具体而言，本研究将着重解决以下几个目标：

（1） 构建面向异常行为检测的多源特征融合模型

异常行为的表现形式多样，在不同摄像头采集的视频中呈现出不同的特征。本研究将探索如何从多个摄像头视频中提取互补性特征，通过特征融合构建统一的特征表达空间，使得异常行为在多源数据融合后能够被更加准确地识别和定位。

（2） 设计时空融合的异常检测算法

在多源视频数据中，异常行为往往具有时空连续性特征。如何有效利用时间序列信息和空间关联信息，设计准确的检测算法，是本研究的核心技术难点之一。研究将探索基于深度学习的端到端检测方法。

（3） 实现异常行为检测后端系统

基于理论研究和算法设计，开发一个集成多源视频数据融合、异常检测和结果输出的后端系统。系统应具备一定的实用性，能够在实验环境中验证算法的有效性。

研究意义：

本研究具有重要的理论意义和实践价值。从理论层面来看，多源视频数据融合与异常行为检测的结合，涉及计算机视觉、模式识别、深度学习等多个研究领域，需要在数据融合理论、特征学习方法、时空建模技术等方面进行深入探索，这将为相关领域的研究提供新的思路和方法。

从实践应用角度，本研究能够显著提升智能监控系统的异常检测能力。在公共安全领域，该技术可以实时识别暴力冲突、非法入侵、异常聚集等危险行为，为安保人员提供及时预警，有效降低安全风险。在智慧交通领域，可以检测交通事故、违章停车、行人闯入等异常事件，提高交通管理效率。在智能楼宇管理中，可以监测异常闯入、火灾烟雾等突发情况，保障建筑安全。

此外，多源视频融合技术能够有效解决单视角监控的遮挡问题和视野盲区问题。通过整合多个视角的信息，即使某个摄像头视野受限或出现遮挡，系统仍然可以从其他视角获取必要的信息，保证异常行为检测的连续性和可靠性。这种互补性和冗余性大大提高了监控系统的鲁棒性。

更重要的是，本研究推动了视频监控技术向智能化、自动化方向发展。传统监控系统主要依赖人工监看，效率低且容易遗漏重要信息。基于多源数据融合的智能异常检测系统可以 7×24 小时不间断工作，自动识别和报警异常事件，极大地减轻了人工监控的负担，提高了监控效率和响应速度。

总之，融合多源视频数据的异常行为检测技术不仅能够克服单视角监控的固有缺陷，还能推动智能监控系统向更加智能、高效、可靠的方向发展。随着技术的不断成熟和应用场景的拓展，该技术将在公共安全、智慧城市建设[1]等领域发挥越来越重要的作用。

2．本课题的国内外的研究现状

异常行为检测是计算机视觉和智能监控领域的重要研究方向。本课题的研究现状主要包括异常行为检测方法、多源视频数据融合技术以及两者结合应用三个方面。

2.1 异常行为检测研究现状

异常行为检测是指在视频序列中自动识别偏离正常模式的行为或事件[2]。根据检测方法的不同,可以分为基于传统机器学习的方法和基于深度学习的方法。

（1） 基于传统机器学习的异常检测方法

早期的异常行为检测主要依赖手工设计的特征和传统机器学习算法。这些方法通常包括特征提取、模型训练和异常判定三个步骤。

基于轨迹的异常检测方法是最早应用的技术之一。Piciarelli 和 Foresti 在 2006 年提出了基于轨迹聚类的异常检测方法[3]，通过分析目标的运动轨迹模式来识别异常行为。该方法假设正常行为遵循某些常见的轨迹模式，偏离这些模式的行为被视为异常。然而，这类方法依赖于准确的目标跟踪，在复杂场景和遮挡情况下性能受限。

基于统计模型的方法通过建立正常行为的统计分布来检测异常。Adam 等人在 2008 年提出了基于光流直方图的异常检测方法[4]，利用局部光流特征的统计分布来建模正常行为模式。Mahadevan 等人在 2010 年提出了基于混合动态纹理（Mixtures of Dynamic Textures， MDT）的异常检测框架[5]，该方法能够捕捉视频中的时空模式变化。这些统计方法的优势在于不需要大量标注数据，但难以处理复杂多变的异常模式。

基于稀疏表示的方法在 2011 年前后得到了广泛研究。Cong 等人提出利用稀疏重构误差来检测异常[6]，正常模式可以用训练样本的线性组合很好地表示，而异常模式则难以表示，重构误差较大。Lu 等人进一步提出了稀疏组合学习框架，提高了检测的鲁棒性。这类方法在理论上较为优雅，但计算复杂度较高。

（2） 基于深度学习的异常检测方法

随着深度学习技术的快速发展，基于神经网络的异常检测方法逐渐成为研究主流，展现出更强的特征学习能力和检测性能。

基于自编码器的方法是深度学习在异常检测中的早期应用。Hasan 等人在 2016 年提出了基于卷积自编码器（Convolutional Autoencoder）的异常检测框架[7]，通过重构误差来识别异常。该方法假设自编码器在正常样本上训练后，对异常样本的重构误差会明显增大。Sabokrou 等人在 2018 年提出了对抗自编码器（Adversarial Autoencoder）框架[8]，结合生成对抗网络的思想提高检测精度。

基于预测模型的方法利用时间序列的可预测性来检测异常。Luo 等人在 2017 年提出了基于时空自编码器的未来帧预测方法[9]，通过预测误差来判断异常。Liu 等人在 2018 年提出了基于光流的未来帧预测网络（Future Frame Prediction Network）[10]，该方法能够捕捉视频中的运动信息，提高了对动态异常的检测能力。Ionescu 等人在 2019 年提出了基于对象中心的自动编码器（Object-Centric Auto-Encoder）[11]，通过学习对象级别的预测模型，进一步提升了检测性能。

基于注意力机制的方法在 2019 年后逐渐兴起。Park 等人提出了基于记忆增强的深度自编码器（Memory-Augmented Deep Autoencoder）[12]，通过记忆模块存储正常模式的原型特征，增强了模型的判别能力。Georgescu 等人在 2021 年提出

了基于自注意力机制的异常检测框架[13]，能够自动关注视频中的关键区域和时间段。

基于 Transformer 的方法代表了最新的研究趋势。Tian 等人在 2021 年提出了基于时空 Transformer 的异常检测模型[14]，利用自注意力机制有效捕捉长距离的时空依赖关系。这类方法在处理复杂场景和长时序列方面表现出色，但计算成本较高。

（3） 弱监督和无监督异常检测

考虑到异常样本标注困难的实际问题，弱监督和无监督学习方法受到了广泛关注。

Sultani 等人在 2018 年提出了基于多示例学习（Multiple Instance Learning， MIL）的弱监督异常检测方法[15]，只需要视频级别的标注而不需要帧级别的精确标注。该方法将视频分为多个片段，通过排序损失函数学习异常得分。Zhong 等人在 2019 年提出了图卷积网络（Graph Convolutional Network，GCN）用于弱监督异常检测[16]，通过构建时序图来建模视频片段之间的关系。

在无监督学习方面，Gong 等人在 2019 年提出了基于记忆模块的无监督异常检测框架 MemAE[17]，通过稀疏记忆寻址机制来增强正常模式的表达能力。Park 等人在 2020 年提出了学习记忆指导的正常性（Learning Memory-guided Normality， LMGN）方法，进一步提升了无监督检测的性能。

2.2 多源视频数据融合研究现状

多源视频数据融合旨在整合来自不同摄像头或传感器的视频信息，构建更加全面和准确的场景理解。根据融合层次的不同，可以分为像素级融合、特征级融合和决策级融合。

（1） 多视角视频处理技术

多视角视频处理是多源数据融合的基础。视角标定和几何对齐是首要解决的问题。Zhang 在 2000 年提出了基于平面棋盘格的相机标定方法[18]，成为多视角系统标定的经典算法。Hartley 和 Zisserman 在其著作《Multiple View Geometry in Computer Vision》中系统阐述了多视角几何理论[19]，为多源视频融合提供了数学基础。

针对多视角目标跟踪，Fleuret 等人在 2008 年提出了基于概率占用图（Probabilistic Occupancy Map， POM）的多视角行人检测方法[20]，通过融合多

个视角的信息来解决遮挡问题。Eshel 和 Moses 在 2008 年提出了基于平面单应性的多视角跟踪方法[21]，能够在地面平面上统一不同视角的目标。

（2） 时空对齐与同步技术

多源视频数据的时空对齐是融合的关键技术。Bradley 等人在 2009 年提出了基于音频信号的多相机时间同步方法，利用音频作为共同参考信号实现精确同步。Pundik 和 Moses 在 2010 年提出了基于视觉特征的视频序列同步方法，通过匹配不同视频中的运动模式来估计时间偏移。

在空间对齐方面，除了传统的相机标定方法，Lowe 在 2004 年提出的 SIFT 特征匹配算法[22]被广泛应用于多视角图像配准。Bay 等人在 2006 年提出的 SURF 算法[23]进一步提高了特征匹配的速度和鲁棒性，使得实时多视角对齐成为可能。

（3） 深度学习时代的多源融合

近年来，深度学习技术为多源视频融合带来了新的突破。Hou 等人在 2019 年提出了基于深度神经网络的多视角特征融合框架[24]，通过端到端学习实现特征级融合。该方法能够自动学习不同视角之间的互补性和关联性，无需人工设计融合规则。

Wang 等人在 2020 年提出了基于注意力机制的多视角融合网络[25]，通过自适应地分配不同视角的权重来提高融合效果。Chen 等人在 2021 年提出了跨视角 Transformer 网络[26]，利用交叉注意力机制实现不同视角之间的信息交互，在多视角行为识别任务中取得了显著性能提升。

2.3 多源视频融合用于异常检测的研究现状

将多源视频融合技术应用于异常行为检测是近年来兴起的研究方向，相关工作还较为有限但发展迅速。

Xu 等人在 2015 年提出了基于多视角协同的异常检测框架[27]，通过融合不同视角的局部特征来提高检测鲁棒性。该方法采用特征级融合策略，将多个视角提取的 HOG 特征和光流特征进行拼接，然后输入到 SVM 分类器进行异常判定。

Leyva 等人在 2017 年提出了基于深度学习的多摄像头异常检测系统[28]，采用卷积神经网络提取每个视角的深度特征，然后通过全连接层进行特征融合。该方法在地铁站监控场景中验证了多视角融合对提高检测准确率的有效性。

Ramachandra 和 Jones 在 2020 年提出了基于 3D 卷积神经网络的多视角异常检测方法[29]，将多个视角的视频帧堆叠成 3D 张量作为网络输入，通过 3D 卷积同时提取时空和跨视角特征。该方法在处理复杂遮挡场景时表现出色。

Wu 等人在 2021 年提出了基于图神经网络的多源异常检测框架[30]，将不同摄像头视为图中的节点，通过图卷积来建模摄像头之间的空间关系和特征交互。该方法特别适合处理大规模摄像头网络的异常检测问题。

2.4 存在的问题与挑战

通过分析现有研究，我们发现多源视频融合异常检测仍面临以下主要挑战：

（1） 视角差异与特征不一致问题

不同摄像头的视角、分辨率、光照条件差异导致提取的特征存在较大不一致性。现有方法大多简单地拼接或平均融合特征，未能充分考虑多摄像头数据间的语义对应关系和互补性，导致融合效果不理想。

（2） 实时性与计算效率问题

多源视频数据量大，深度学习模型计算复杂度高，难以满足实时监控的需求。尤其是在多摄像头同时处理的场景下，如何在保证检测精度的同时提高计算效率，是工程实现的关键瓶颈。

（3） 时空同步与数据关联问题

多个摄像头可能存在时间延迟，且在不同视角下同一异常事件的表现形式可能不同。如何实现精确的时空同步，并建立跨源的事件关联模型，仍是技术难点。

（4） 复杂场景下的鲁棒性问题

在人群密集、光照变化、天气变化等复杂场景下，单一摄像头的检测性能会显著下降。虽然多源融合理论上可以提高鲁棒性，但现有方法在极端条件下的表现仍不够稳定。

（5） 异常样本稀缺与模型泛化问题

真实场景中异常事件发生频率低，标注数据稀缺，导致监督学习方法难以获得充足的训练样本。如何在少样本甚至零样本条件下实现有效的异常检测，是亟待解决的问题。

3. 本课题的研究内容

3.1 多源视频数据预处理与时空对齐

多源视频数据来自不同位置、不同角度的摄像头，存在时间不同步、空间坐标系不统一等问题。有效的预处理和时空对齐是后续融合和检测的基础。

（1） 时间同步策略

针对多摄像头之间可能存在的时间延迟，采用基于事件触发的时间对齐方法。具体而言，利用场景中的共同可见事件（如运动目标的出现、消失）作为时间参考点，通过匹配这些事件在不同视频流中的发生时刻来估计时间偏移量。对于没有明显事件触发的视频段，采用基于光流场相似度的时间对齐算法，通过最大化不同视角运动模式的相关性来确定时间同步参数。

（2） 空间标定与几何对齐

采用基于特征点匹配的摄像头标定方法，提取场景中的显著特征点（如建筑物角点、地面标志等），建立不同摄像头之间的几何变换关系。利用单应性矩阵或基础矩阵描述视角间的投影关系，将不同视角的图像映射到统一的坐标系（如鸟瞰图坐标系或某一参考视角坐标系）。对于动态场景，采用 RANSAC 算法剔除异常匹配点，提高几何对齐的鲁棒性。

（3） 图像质量评估与增强

由于不同摄像头的成像质量可能存在差异，需要对视频帧进行质量评估。基于图像清晰度、对比度、亮度等指标，自动识别低质量帧并进行相应的增强处理。对于光照不均匀的情况，采用直方图均衡化或自适应 gamma 校正方法进行亮度归一化。对于模糊帧，可以采用去模糊算法或直接剔除，避免影响后续的特征提取和融合效果。

3.2 多源特征提取与表达

不同摄像头采集的视频中，同一异常行为的视觉表现可能存在较大差异。构建鲁棒且具有判别力的多源特征表达是异常检测的关键。

（1） 多源特征提取网络

设计一个多分支卷积神经网络结构，每个分支对应一个摄像头的视频输入。各分支采用相同的网络架构但不共享权重,能够学习到摄像头特定的特征表达。网络采用时空卷积结构（如 3D-CNN 或（2+1）D-CNN）,能够同时捕捉空间外观特

征和时间运动特征。在网络的中间层引入摄像头编码信息，使得模型能够显式地学习不同摄像头的特性。

（2） 跨摄像头特征对齐与关联

由于不同摄像头提取的特征存在于不同的特征空间，需要进行特征对齐以建立语义对应关系。采用基于注意力机制的特征对齐模块，通过计算不同摄像头特征之间的相似度矩阵，自动学习摄像头间的对应关系。具体而言，对于摄像头 A 的特征向量，通过与摄像头 B 的所有特征向量计算注意力权重，加权求和得到对齐后的特征。这种软对应的方式能够处理遮挡和视野不重叠的情况。

（3） 多尺度时空特征融合

异常行为可能发生在不同的时间尺度和空间尺度上。采用多尺度特征提取策略，在不同的感受野大小下提取特征，然后通过特征金字塔融合。时间尺度上，采用不同步长的时间卷积核捕捉短期和长期的时序模式。空间尺度上，采用不同大小的空间卷积核提取局部和全局的外观特征。多尺度特征通过自适应加权融合，形成最终的特征表达。

3.3 基于深度学习的多源融合异常检测模型

在多源特征的基础上，设计端到端的异常检测模型，实现从原始视频到异常判定的自动化处理。

（1） 多源融合策略设计

探索三种不同层次的融合策略并进行对比分析：

早期融合（Early Fusion）：在特征提取之前将不同摄像头的图像拼接或堆叠，输入到统一的网络中。这种方式简单直接，但可能损失摄像头特定信息。

中期融合（Mid-level Fusion）：各摄像头独立提取浅层特征，然后在网络的中间层进行融合，继续通过深层网络提取融合后的高层特征。这种方式能够平衡摄像头特定性和跨摄像头一致性。

晚期融合（Late Fusion）：各摄像头独立完成特征提取和初步判定，然后在决策层进行融合。这种方式保留了较多的摄像头特定信息，但可能无法充分利用摄像头间的互补性。

本研究将重点研究特征级融合策略,通过设计注意力模块来实现特征的动态融合,使模型能够根据具体情况自适应地选择融合方式。

（2） 基于记忆增强的正常模式建模

借鉴记忆网络的思想，构建一个记忆模块来存储正常行为模式的原型特征。记忆模块包含一组固定大小的记忆槽，每个记忆槽存储一个正常模式的特征向量。在训练阶段，通过自编码器重构损失和记忆寻址损失，使得正常样本能够被记忆模块很好地表达，而异常样本无法在记忆中找到合适的表达。在测试阶段，根据输入特征与记忆内容的匹配程度（如余弦相似度或欧氏距离）来判定异常。

（3） 时序建模与异常定位

采用时序建模网络（如 LSTM 或 Transformer）来捕捉视频中的时间依赖关系。将融合后的多视角特征作为时序输入，通过循环结构或自注意力机制学习正常行为的时序模式。在异常检测时，不仅需要判断视频段是否包含异常，还需要定位异常发生的具体时间和空间位置。采用时空注意力机制，输出每个时间步和每个空间位置的异常得分，实现细粒度的异常定位。

（4） 损失函数设计

设计组合损失函数来训练模型。损失函数包含以下几个部分：

重构损失：自编码器的重构误差，用于学习正常模式的表达。

记忆紧凑性损失：鼓励记忆模块学习到多样且紧凑的正常模式原型。

分离性损失：在弱监督或半监督设置下，鼓励正常样本和异常样本的特征在潜在空间中分离。

通过多任务学习框架联合优化这些损失，提高模型的检测性能和泛化能力。

3.4 系统实现与性能优化

基于前述算法设计，实现一个完整的多源视频异常检测系统，并进行性能优化以满足实时性要求。

（1） 系统架构设计

采用分布式处理架构，将视频采集、特征提取、融合检测和结果展示等模块进行解耦。视频采集模块负责从多个摄像头同时获取视频流，并进行初步的预处理和缓存。特征提取模块部署在 GPU 服务器上，对每个视角的视频并行提取深度特征。融合检测模块接收所有视角的特征，进行融合和异常判定，输出异常报警信息。结果展示模块将检测结果可视化，标注异常区域并推送报警信息。

（2） 模型压缩与加速

为了满足实时性要求，对深度学习模型进行压缩和加速。采用知识蒸馏方法，将复杂的教师模型知识迁移到轻量级的学生模型。采用模型剪枝技术，移除

不重要的网络连接和通道，减少计算量。采用模型量化技术，将浮点运算转换为低精度整数运算，提高推理速度。在保证检测精度基本不下降的前提下，力求将模型推理速度提升到实时处理水平。

（3） 鲁棒性增强策略

针对实际应用中可能出现的摄像头故障、网络延迟、光照突变等情况，设计鲁棒性增强策略。当某个摄像头信号丢失或质量严重下降时，系统能够自动切换到其他视角继续检测，保证服务不中断。采用在线学习和模型自适应机制，使模型能够逐步适应环境变化和新的正常模式，减少误报率。

4. 本课题的实行方案、进度及预期效果

实行方案：

本课题采用自底向上的研究方法，从数据预处理、特征提取、模型构建到系统集成逐步推进。

首先，进行多源视频数据的预处理与时空对齐研究。针对不同摄像头之间存在的时间延迟和空间坐标不统一问题，研究基于事件触发和光流匹配的时间同步方法，以及基于特征点匹配的空间几何对齐方法，为后续处理奠定数据基础。

其次,构建多源特征提取与融合模型。设计多分支深度神经网络结构，每个分支独立提取单个摄像头视频的时空特征。引入注意力机制实现不同摄像头特征的语义对齐，并通过特征融合策略整合互补信息，形成鲁棒的多源联合特征表达。

然后，开发基于深度学习的异常检测算法。采用记忆增强网络建模正常行为模式，结合时序建模网络捕捉视频中的时间依赖关系。设计组合损失函数进行端到端训练，实现从原始视频到异常判定的自动化处理，并能够定位异常发生的时空位置。

最后,进行系统集成与性能优化。构建处理框架实现多路视频的处理流程，通过模型优化技术提升处理效率，实现完整的检测功能并输出检测结果。

4.1 项目数据集

本课题将采用公开数据集进行实验验证，主要包括 UCF-Crime、ShanghaiTech、Avenue 等经典异常检测数据集。针对多源数据集稀缺的问题，将通过转化利用多摄像头行为识别数据集(如 IXMAS、MuHAVi 等)，并结合数据增强等方法来验证算法的有效性。

4.2 实施步骤

（1） 数据预处理模块开发

使用 OpenCV 实现视频采集、时间同步和空间对齐功能。通过光流计算和特征点匹配实现多源数据的几何校正，建立统一的时空坐标系。实现图像质量评估与增强模块，对低质量帧进行处理或剔除。

（2） 特征提取网络构建

基于 PyTorch 框架构建多分支 3D 卷积神经网络，采用（2+1）D 卷积结构实现时空特征提取。设计注意力模块，通过注意力机制实现不同摄像头特征的对齐和融合。实现多尺度特征提取，捕捉不同层次的时空信息。

（3） 异常检测模型实现

构建记忆增强模块，使用可学习的记忆矩阵存储正常模式原型。实现时序建模网络（LSTM 或 Transformer），捕捉视频中的时间依赖关系。设计组合损失函数，包括重构损失、记忆紧凑性损失和时序平滑损失，进行端到端训练。

（4） 系统集成与优化

实现多路视频处理框架。通过模型优化技术提升处理效率。实现完整的检测流程，包括数据输入、特征提取、异常检测和结果输出功能。

4.3 评估指标

采用异常检测领域标准评估指标:AUC（ROC 曲线下面积）、准确率、召回率、F1 值、误报率（FAR）、处理速度（FPS）等，全面评估算法性能。

进度安排：

2026 年 1-2 月：文献调研，学习相关技术，收集整理数据集，开始编写相关代码。

2026 年 3 月：系统集成，模型优化，完善检测流程。

2026 年 4 月：实验评估，撰写论文初稿。

预期效果：

（1） 提出完整的多源视频时空对齐方法和多源特征融合框架，构建融合记忆增强和时序建模的异常检测模型。

（2） 完成多源视频异常检测系统原型，实现多路视频处理流程，具备异常检测和结果输出功能。

（3） 为智能监控系统提供更准确、更鲁棒的异常检测能力，可应用于智慧城市、智能交通、平安校园等领域，推动视频监控智能化发展。

5. 已查阅参考文献

[1] 黄凯奇, 陈晓棠, 康运锋, 等. 智能视频监控技术综述[J]. 计算机学报, 2015, 38(6): 1093-1118.

[2] CHANDOLA V, BANERJEE A, KUMAR V. Anomaly detection: A survey[J]. ACM Computing Surveys, 2009, 41(3): 1-58.

[3] PICIARELLI C, FORESTI G L. Surveillance-oriented event detection in video streams[J]. IEEE Intelligent Systems, 2011, 26(3): 32-41.

[4] ADAM A, RIVLIN E, SHIMSHONI I, et al. Robust real-time unusual event detection using multiple fixed-location monitors[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2008, 30(3): 555-560.

[5] MAHADEVAN V, LI W, BHALODIA V, et al. Anomaly detection in crowded scenes[C]//2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. IEEE, 2010: 1975-1981.

[6] CONG Y, YUAN J, LIU J. Sparse reconstruction cost for abnormal event detection[C]//CVPR 2011. IEEE, 2011: 3449-3456.

[7] HASAN M, CHOI J, NEUMANN J, et al. Learning temporal regularity in video sequences[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 733-742.

[8] SABOKROU M, FAYYAZ M, FATHY M, et al. Deep-anomaly: Fully convolutional neural network for fast anomaly detection in crowded scenes[J]. Computer Vision and Image Understanding, 2018, 172: 88-97.

[9] LUO W, LIU W, GAO S. A revisit of sparse coding based anomaly detection in stacked rnn framework[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 341-349.

[10] LIU W, LUO W, LIAN D, et al. Future frame prediction for anomaly detection–a new baseline[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 6536-6545.

[11] IONESCU R T, KHAN F S, GEORGESCU M I, et al. Object-centric auto-encoders and dummy anomalies for abnormal event detection in video[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 7842-7851.

[12] PARK H, NOH J, HAM B. Learning memory-guided normality for anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 14372-14381.

[13] GEORGESCU M I, BARBALAU A, IONESCU R T, et al. Anomaly detection in video via self-supervised and multi-task learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 12742-12752.

[14] TIAN Y, PANG G, CHEN Y, et al. Weakly-supervised video anomaly detection with robust temporal feature magnitude learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 4975-4986.

[15] SULTANI W, CHEN C, SHAH M. Real-world anomaly detection in surveillance videos[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 6479-6488.

[16] ZHONG J X, LI N, KONG W, et al. Graph convolutional label noise cleaner: Train a plug-and-play action classifier for anomaly detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 1237-1246.

[17] GONG D, LIU L, LE V, et al. Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1705-1714.

[18] ZHANG Z. A flexible new technique for camera calibration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.

[19] HARTLEY R, ZISSERMAN A. Multiple view geometry in computer vision[M]. Cambridge University Press, 2003.

[20] FLEURET F, BERCLAZ J, LENGAGNE R, et al. Multicamera people tracking with a probabilistic occupancy map[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2008, 30(2): 267-282.

[21] ESHEL R, MOSES Y. Homography based multiple camera detection and tracking of people in a dense crowd[C]//2008 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2008: 1-8.

[22] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.

[23] BAY H, TUYTELAARS T, VAN GOOL L. SURF: Speeded up robust features[C]//European Conference on Computer Vision. Springer, 2006: 404-417.

[24] HOU R, CHEN C, SHAH M. Tube convolutional neural network (T-CNN) for action detection in videos[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 5822-5831.

[25] ANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7794-7803.

[26] CHEN Y, KALANTIDIS Y, LI J, et al. A^2-nets: Double attention networks[C]//Advances in Neural Information Processing Systems. 2018: 352-361.

[27] XU D, YAN Y, RICCI E, et al. Multi-view learning with incomplete views[J]. IEEE Transactions on Image Processing, 2015, 24(12): 5812-5825.

[28] LEYVA R, SANCHEZ V, LI C T. Video anomaly detection with compact feature sets for online performance[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3463-3478.

[29] RAMACHANDRA B, JONES M. Street scene: A new dataset and evaluation protocol for video anomaly detection[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2020: 2569-2578.

[30] WU P, LIU J, SHI Y, et al. Not only look, but also listen: Learning multimodal violence detection under weak supervision[C]//European Conference on Computer Vision. Springer, 2020: 322-339.

指导教师意见

本课题任务明确，具有一定理论和实践意义。该同学经过前期的积极调研，通过学习、理解和总结前人的一些研究成果，提出了解决问题的方法和思路，并且也进行初步尝试，后面准备编程加以实现。从实现方案来看是可行的，进度安排也是合理的，同意开题，并希望严格按照进度完成课题和论文。

指导教师： 胡勇

2026 年 1 月 16 日

院（系）审查意见

同意开题。

学院领导（公章）：